



AI TRACEFINDER: FORENSIC SCANNER IDENTIFICATION



A Machine Learning & Deep Learning Based System
for Scanner Source Identification

Presented by:
Tejaswini Dhamane


INTRODUCTION

Problem Background:

- Digital documents are widely used in legal, academic, and corporate environments
- Forged or unauthorized scanned documents pose serious risks
- Each scanner leaves unique invisible artifacts during scanning
- These artifacts can be learned and identified using AI techniques

Objective:

To automatically identify the source scanner type used to scan a document.



MOTIVATION & USE CASES

Why Scanner Identification?

- Prevent document forgery
- Ensure authenticity of scanned records
- Support forensic investigations

Key Use Cases

- Digital forensics
- Legal document verification
- Government and enterprise document authentication
- Copyright protection



PROJECT OBJECTIVES

1

Identify scanner source from scanned images

2

Learn scanner-specific noise and texture patterns

3

Build a robust classification model

4

Provide confidence score with prediction

5

Deploy a simple and usable interface


6

Log predictions for audit and analysis

SYSTEM OVERVIEW

High-Level Workflow

1. Input scanned document image
2. Image preprocessing
3. Feature extraction / Deep feature learning
4. Model prediction
5. Confidence estimation
6. Result visualization & logging



DATASET DESCRIPTION

Dataset Source

- Public dataset (Kaggle)
- Multiple scanned documents from different sources

Dataset Characteristics

- Grayscale & color scanned documents
- Different resolutions and formats
- Labeled into:
 - Official scanned images
 - Non-official / Wiki scanned images

Preprocessing

- Resized to fixed dimensions (224×224)
- Normalized pixel values

FEATURE ENGINEERING (BASELINE)



Traditional Feature Extraction

- Noise patterns
- Frequency-domain features (FFT)
- Texture descriptors

Baseline Models

- Logistic Regression
- SVM
- Random Forest

Observation

- Limited performance
- Difficulty capturing subtle scanner artifacts

DEEP LEARNING **MODEL**

CNN-BASED APPROACH

- Automatically learns scanner-specific artifacts
- No manual feature engineering required
- Better generalization on unseen images

MODEL HIGHLIGHTS

- Automatically learns scanner-specific artifacts
- No manual feature engineering required
- Better generalization on unseen images


MODEL TRAINING & EVALUATION

Training Strategy


- Train-validation split
- Data augmentation for robustness
- Loss & accuracy monitoring

Evaluation Metrics

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix



Accuracy plot



Loss plot

MODEL CONFIDENCE & RELIABILITY

Why Confidence Score Matters?

- Prediction alone is not sufficient in forensic applications
- Confidence score indicates reliability of prediction
- Helps investigators make informed decisions

How Confidence is Computed?

- Model outputs probability value (0–1)
- Threshold-based classification
- Higher confidence → stronger scanner signature

Displayed in UI

- Confidence shown along with prediction
- Logged for audit and traceability

selon les priorités de l'économie nationale, notamment à travers :

- l'augmentation de la valeur ajoutée, de la compétitivité et de la capacité d'exportation de l'économie nationale et de son contenu technologique aux niveaux régional et international, ainsi que le développement des secteurs prioritaires,
- la création d'emplois et la promotion de la compétence des ressources humaines,
- la réalisation d'un développement régional intégré et équilibré,
- la réalisation d'un développement durable.

Art. 2 - La présente loi fixe le régime juridique de l'investissement réalisé par des personnes physiques ou morales, résidentes ou non résidentes, dans toutes les activités économiques.

Les activités économiques sont classées conformément à « la nomenclature d'activités tunisienne », adoptée uniformément par tous les services publics intervenant dans l'investissement.

La nomenclature d'activités tunisienne est fixée par décret gouvernemental.

(1) Travaux préparatoires :
Discussion et adoption par l'assemblée des représentants du peuple dans sa séance du 17 septembre 2016.

2. Opération d'investissement par participation : la participation en numéraire ou en nature dans le capital de sociétés établies en Tunisie, et ce, lors de leur constitution ou de l'augmentation de leurs capitaux sociaux ou de l'acquisition d'une participation à leurs capitaux.

- **Investisseur :** toute personne physique ou morale, résidente ou non résidente, qui réalise un investissement.
- **Entreprise :** toute unité qui a pour but de produire des biens ou de fournir des services et qui prend la forme d'une société ou d'une entreprise individuelle conformément à la législation tunisienne.
- **Indice de développement régional :** indice élaboré par le ministère chargé du développement, calculé selon des critères économiques, sociaux, démographiques et environnementaux pour classer les zones du pays selon l'évolution de leur degré de développement.
- **Conseil :** conseil supérieur de l'investissement.
- **Instance :** instance tunisienne de l'investissement.
- **Fonds :** fonds tunisien de l'investissement.

TITRE II
L'ACCES AU MARCHÉ

Art. 4 - L'investissement est libre.

Les opérations d'investissement doivent se conformer à la législation relative à l'exercice des activités économiques.

N° 82 Journal Officiel de la République Tunisienne — 7 octobre 2016 Page 3083

Uploaded Image

Prediction: Official Image

Confidence: 0.53

Download Prediction Log

Streamlit UI showing confidence

DEPLOYMENT ARCHITECTURE

Frontend

- Streamlit-based web application

Backend

- Trained CNN model (TensorFlow / Keras)

Functionality


- Upload scanned image
- Get prediction with confidence score
- Store prediction logs
- Download result file



USER INTERFACE DEMO

Application Features

- Image upload
- Real-time prediction
- Confidence score display
- Prediction logging
- Downloadable CSV log



RESULTS & OBSERVATIONS



Key Results

- Successful classification of scanned images
- Confidence score provided for each prediction
- Model generalizes well to unseen images



Observations

- CNN significantly outperforms baseline models
- Scanner artifacts are consistent and learnable

LIMITATIONS & FUTURE SCOPE

CURRENT LIMITATIONS

- Limited number of scanner types
- Binary classification setup
- Dataset size constraints

FUTURE ENHANCEMENTS

- Limited number of scanner types
- Binary classification setup
- Dataset size constraints

CONCLUSION

- Successfully built an end-to-end scanner identification system
- Combined ML, Deep Learning, and deployment
- Achieved practical forensic relevance
- Demonstrated real-world applicability with UI

AI TraceFinder proves that scanner source identification is feasible using deep learning.

A top-down view of a desk with various items: a laptop, a cup of coffee, a pen, a notebook, glasses, and a plant. The text "THANK YOU!" is centered in the middle of the image.

THANK YOU!